

Laboratorio 3

Daniel Machic (22118), María José Ramírez (221051)

Introducción

Este informe detalla el proceso de construcción, entrenamiento y evaluación de varios modelos de redes neuronales para la clasificación de imágenes de dígitos manuscritos. El objetivo principal del laboratorio es comparar la efectividad de diferentes arquitecturas de Redes Neuronales Convolucionales (CNN) frente a una red neuronal densa tradicional en el conjunto de datos PolyMNIST. El conjunto de datos PolyMNIST es una variante del conocido conjunto de datos MNIST, que incluye múltiples modalidades de cada dígito (representadas por las carpetas m0 a m4), ofreciendo así una mayor variabilidad. A través de este proyecto, se busca no solo alcanzar una alta precisión en la clasificación, sino también entender el impacto de la profundidad de la red, las técnicas de regularización como el Dropout y el aumento de datos (Data Augmentation) en el rendimiento del modelo.

2. Metodología

El proceso se dividió en cuatro etapas principales: preparación de datos, preprocesamiento, diseño de arquitecturas y entrenamiento.

2.1. Preparación de Datos

- **Fuente de Datos:** Se utilizaron las imágenes del conjunto de datos PolyMNIST, específicamente las modalidades m0, m1, m2, m3 y m4 del conjunto de entrenamiento.
- **Combinación y División:** Todas las modalidades se combinaron en un único conjunto de datos. Posteriormente, este conjunto se dividió aleatoriamente en un conjunto de entrenamiento (75%) y un conjunto de validación (25%).
- **Estructura de Carpetas:** Las imágenes se reorganizaron en una estructura de carpetas compatible con los generadores de datos de Keras. Se crearon directorios train y val, cada uno con 10 subcarpetas (una por cada dígito, del 0 al 9). Las imágenes se copiaron a su respectiva carpeta de clase.

2.2. Preprocesamiento de Imágenes

Se aplicaron las siguientes transformaciones a todas las imágenes antes de ser introducidas a los modelos:

- **Cambio de Tamaño:** Todas las imágenes se redimensionaron a un formato estándar de 64x64 píxeles y se cargaron en modo de color RGB (3 canales).

- **Reescalado (Normalización):** Los valores de los píxeles, originalmente en el rango, se normalizaron al rango dividiéndolos por 255.0. Esto ayuda a estabilizar y acelerar el entrenamiento.
- **Codificación de Etiquetas:** Las etiquetas de clase (0-9) se convirtieron a un formato de one-hot encoding usando `to_categorical`, generando vectores de 10 posiciones.

2.3. Arquitecturas de Modelos

Se diseñaron y compararon cuatro modelos de CNN y un modelo de red densa como base de referencia.

- **Modelo 1 (CNN Simple):** Una arquitectura básica con un bloque convolucional (Conv2D con 32 filtros y activación ReLU), seguido de una capa de MaxPooling2D, una capa Flatten para aplanar los datos y dos capas densas para la clasificación.
- **Modelo 2 (CNN VGG):** Un modelo más profundo, inspirado en la arquitectura VGG. Consta de dos bloques convolucionales. El primero con 32 filtros y el segundo con 64 filtros, ambos seguidos de MaxPooling2D. Finaliza con capas Flatten y densas.
- **Modelo 3 (CNN con Dropout):** Idéntico al Modelo 2, pero con la adición de capas de Dropout (tasa de 0.1) después de cada capa de MaxPooling2D para regularizar el modelo y prevenir el sobreajuste.
- **Modelo 4 (CNN con Aumento de Datos):** Utiliza la misma arquitectura que el Modelo 2, pero se entrena con un generador de datos que aplica aumento de datos en tiempo real (desplazamientos horizontales y verticales, y volteo horizontal).
Modelo Alternativo (Red Densa): Un modelo sin capas convolucionales, compuesto únicamente por una capa Flatten y capas densas (Dense). Sirve como modelo de referencia para evaluar la ventaja de las convoluciones.

2.4. Entrenamiento

Todos los modelos fueron compilados usando la función de pérdida `categorical_crossentropy`, adecuada para clasificación multiclase. Se utilizó principalmente el optimizador SGD con momento, y Adam para la red densa. El entrenamiento se realizó por lotes de 64 imágenes durante 5 a 10 épocas, dependiendo del modelo.

Análisis Exploratorio Y Código

Importando los paquetes necesarios

```
import os
import shutil
import random
import numpy as np
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt
```

```

from matplotlib.image import imread
from tensorflow import keras
from tensorflow.keras.preprocessing.image import load_img,
img_to_array
from tensorflow.keras.utils import to_categorical
from tensorflow.keras.preprocessing.image import ImageDataGenerator
from tensorflow.keras.preprocessing import image as kerasImg

folder = "/Users/danielmachic/Desktop/Data
Science/CNN/archive/PolyMNIST/MMNIST/train/m0/"

base_folder = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/"
train_folder = os.path.join(base_folder, "train")  # imágenes
organizadas por clases 0-9
val_folder = os.path.join(base_folder, "val")      # validación
organizada igual

```

División de imágenes por número

```

# Rutas base
src_base = "/Users/danielmachic/Desktop/Data
Science/CNN/archive/PolyMNIST/MMNIST/train/"
dest_base = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/"

# Subcarpetas nuevas separación de carpetas por número
subdirs = ['train', 'val']
labels = [str(i) for i in range(10)]  # dígitos del 0 al 9

# Crear carpetas destino (una por clase/dígito)
for subdir in subdirs:
    for label in labels:
        newdir = os.path.join(dest_base, subdir, label)
        os.makedirs(newdir, exist_ok=True)

# Fijar semilla para reproducibilidad
random.seed(1)
val_ratio = 0.25

# Recorrer carpetas m0 a m4
modalities = ['m0', 'm1', 'm2', 'm3', 'm4']
for modality in modalities:
    src_dir = os.path.join(src_base, modality)
    for img_name in os.listdir(src_dir):
        try:
            # Obtener etiqueta desde el nombre del archivo (después
            del punto)
            label = img_name.split(".")[1]
            if label not in labels:

```

```

        continue # ignorar si no es una etiqueta válida

    # Decidir destino
    subset = 'val' if random.random() < val_ratio else 'train'
    dest_dir = os.path.join(dest_base, subset, label)

    # Copiar imagen
    src_path = os.path.join(src_dir, img_name)
    dest_path = os.path.join(dest_dir,
f"{modality}_{img_name}") # mantener el origen en el nombre
    shutil.copy2(src_path, dest_path)
    except Exception as e:
        print(f"Error copiando {img_name}: {e}")

# Validación de que las carpetas sean creadas correctamente
train_path = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/train/"
print("Carpetas en train:", os.listdir(train_path))

val_path = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/val/"
print("Carpetas en val:", os.listdir(val_path))

Carpetas en train: ['9', '0', '7', '6', '1', '8', '4', '3', '2', '5']
Carpetas en val: ['9', '0', '7', '6', '1', '8', '4', '3', '2', '5']

```

Cargar todas en memoria

```

# Carpetas base reorganizadas por clases (0 a 9)
base_path = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/"
train_path = os.path.join(base_path, "train")
val_path = os.path.join(base_path, "val")

# Contenedores
fotos_train = []
etiquetas_train = []
fotos_val = []
etiquetas_val = []

# Dimensiones estándar
target_size = (64, 64)

# Leer carpetas por clase
clases = sorted([
    d for d in os.listdir(train_path)
    if os.path.isdir(os.path.join(train_path, d))
])

# Cargar imágenes de entrenamiento

```

```

for clase in clases:
    clase_dir = os.path.join(train_path, clase)
    for file in os.listdir(clase_dir):
        img_path = os.path.join(clase_dir, file)
        image = load_img(img_path, target_size=target_size,
color_mode="rgb")
        image = img_to_array(image)
        fotos_train.append(image)
        etiquetas_train.append(int(clase)) # Usamos el nombre de la
carpeta como clase

# Cargar imágenes de validación
for clase in clases:
    clase_dir = os.path.join(val_path, clase)
    for file in os.listdir(clase_dir):
        img_path = os.path.join(clase_dir, file)
        image = load_img(img_path, target_size=target_size,
color_mode="rgb")
        image = img_to_array(image)
        fotos_val.append(image)
        etiquetas_val.append(int(clase))

# Convertir a arrays
fotos_train = np.asarray(fotos_train, dtype=np.float32) / 255.0 #
Normalizar
etiquetas_train = np.asarray(etiquetas_train)

fotos_val = np.asarray(fotos_val, dtype=np.float32) / 255.0
etiquetas_val = np.asarray(etiquetas_val)

print("Train:", fotos_train.shape, etiquetas_train.shape)
print("Val:  ", fotos_val.shape, etiquetas_val.shape)

Train: (224641, 64, 64, 3) (224641,)
Val:   (75359, 64, 64, 3) (75359,)

# Guardar
np.save("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_photos_train.npy", fotos_train)
np.save("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_labels_train.npy", etiquetas_train)

np.save("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_photos_val.npy", fotos_val)
np.save("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_labels_val.npy", etiquetas_val)

fotos_train = np.load("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_photos_train.npy")
etiquetas_train = np.load("/Users/danielmachic/Desktop/Data

```

```

Science/CNN/polyMNIST_labels_train.npy")

fotos_val = np.load("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_photos_val.npy")
etiquetas_val = np.load("/Users/danielmachic/Desktop/Data
Science/CNN/polyMNIST_labels_val.npy")

print("Train:", fotos_train.shape, etiquetas_train.shape)
print("Val:  ", fotos_val.shape, etiquetas_val.shape)

Train: (224641, 64, 64, 3) (224641,)
Val:   (75359, 64, 64, 3) (75359,)

# Ahora hay 10 clases (0 a 9)
etiquetas_train_ohe = to_categorical(etiquetas_train, num_classes=10)
etiquetas_val_ohe = to_categorical(etiquetas_val, num_classes=10)

```

Documentación de las transformaciones aplicadas

Transformaciones aplicadas:

1. Reescalado: Todas las imágenes se normalizan dividiendo por 255.0 para que los valores estén en [0,1].
2. Cambio de tamaño: Todas las imágenes se redimensionan a 64x64 píxeles.
3. Data Augmentation (solo para entrenamiento en modelo4):
 - width_shift_range=0.1 (corrimientos horizontales aleatorios)
 - height_shift_range=0.1 (corrimientos verticales aleatorios)
 - horizontal_flip=True (volteo horizontal aleatorio)
4. One-hot encoding: Las etiquetas son codificadas en vectores de 10 posiciones (una por clase) usando 'to_categorical'.

Análisis Exploratorio

Veamos si el conjunto de datos está balanceado

```

for i, img_name in enumerate(os.listdir(folder)[:9]):
    plt.subplot(330 + 1 + i)
    image = imread(os.path.join(folder, img_name))
    plt.imshow(image)
    plt.axis('off')
plt.tight_layout()
plt.show()

```



```
# Rutas
train_path = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/train"
val_path = "/Users/danielmachic/Desktop/Data
Science/CNN/PolyMNIST_CNN/val"

# Contar ejemplos por clase
def contar_clases(path):
    conteos = {}
    for clase in os.listdir(path):
        clase_path = os.path.join(path, clase)
        if os.path.isdir(clase_path):
            conteos[clase] = len(os.listdir(clase_path))
    return conteos

conteo_train = contar_clases(train_path)
conteo_val = contar_clases(val_path)

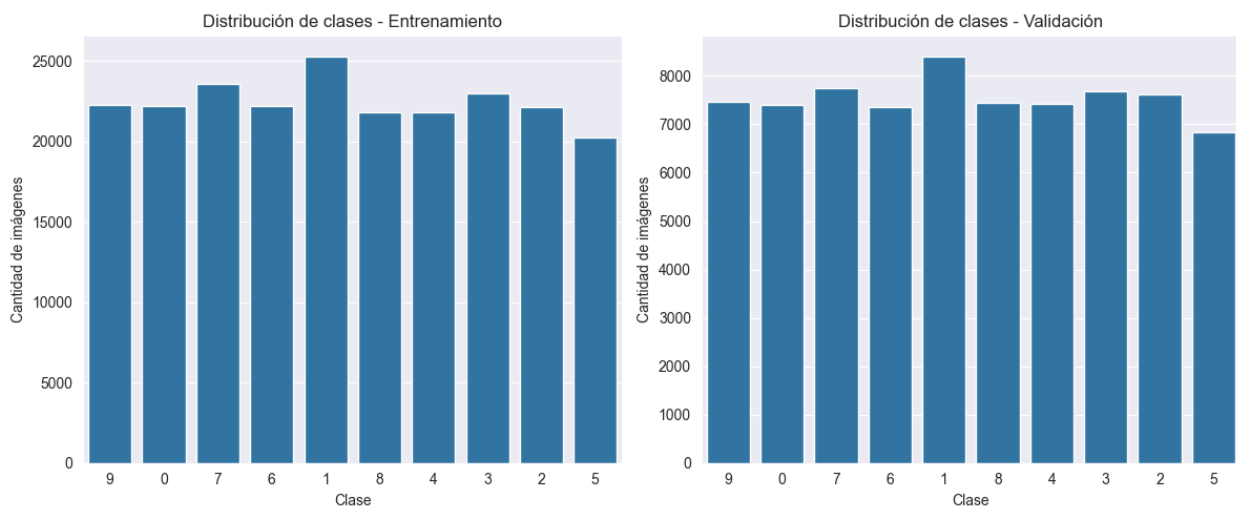
# Graficar
plt.figure(figsize=(12,5))
plt.subplot(1,2,1)
sns.barplot(x=list(conteo_train.keys()),
```

```

y=list(conteo_train.values()))
plt.title("Distribución de clases - Entrenamiento")
plt.xlabel("Clase")
plt.ylabel("Cantidad de imágenes")

plt.subplot(1,2,2)
sns.barplot(x=list(conteo_val.keys()), y=list(conteo_val.values()))
plt.title("Distribución de clases - Validación")
plt.xlabel("Clase")
plt.ylabel("Cantidad de imágenes")
plt.tight_layout()
plt.show()

```



Tanto el conjunto de entrenamiento como el de validación están balanceados. Esto es positivo, ya que los modelos entrenados no estarán inclinados a favorecer una clase sobre otra simplemente por mayor frecuencia en los datos.

Además los datos cuentan con una dimensión de 64x64 píxeles y 3 canales de colores RGB.

CNN Simple

```

modelo1 = keras.Sequential()
modelo1.add(keras.layers.Conv2D(32, (3,3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=(64, 64,
3)))
modelo1.add(keras.layers.MaxPooling2D((2,2)))
modelo1.add(keras.layers.Flatten())
modelo1.add(keras.layers.Dense(128, activation='relu',
kernel_initializer='he_uniform'))
modelo1.add(keras.layers.Dense(10, activation='softmax')) # ← 10
clases ahora

# Compilar
opt = keras.optimizers.SGD(learning_rate=0.01, momentum=0.9)

```



```

modelo1.compile(optimizer=opt, loss='categorical_crossentropy',
metrics=['accuracy'])
modelo1.summary()

```

```

/Users/danielmachic/Library/Python/3.9/lib/python/site-packages/
keras/src/layers/convolutional/base_conv.py:113: UserWarning: Do not
pass an `input_shape`/`input_dim` argument to a layer. When using
Sequential models, prefer using an `Input(shape)` object as the first
layer in the model instead.

```

```

super().__init__(activity_regularizer=activity_regularizer,
**kwargs)

```

Model: "sequential"

Layer (type) Param #	Output Shape
conv2d (Conv2D) 896	(None, 64, 64, 32)
max_pooling2d (MaxPooling2D) 0	(None, 32, 32, 32)
flatten (Flatten) 0	(None, 32768)
dense (Dense) 4,194,432	(None, 128)
dense_1 (Dense) 1,290	(None, 10)

Total params: 4,196,618 (16.01 MB)

Trainable params: 4,196,618 (16.01 MB)

Non-trainable params: 0 (0.00 B)

Entrenamos el modelo Simple

```

# Ruta base
folder = "/Users/danielmachic/Desktop/Data Science/CNN/PolyMNIST_CNN/"

```

```
# Normalización
datagen = ImageDataGenerator(rescale=1.0/255.0)
```

```
# Generador para entrenamiento
train_it = datagen.flow_from_directory(
    directory=os.path.join(folder, "train"),
    class_mode='categorical',
    batch_size=64,
    target_size=(64, 64))
```

```
# Generador para validación
val_it = datagen.flow_from_directory(
    directory=os.path.join(folder, "val"),
    class_mode='categorical',
    batch_size=64,
    target_size=(64, 64))
```

```
Found 224641 images belonging to 10 classes.
Found 75359 images belonging to 10 classes.
```

```
history = model1.fit(
    train_it,
    steps_per_epoch=train_it.samples // train_it.batch_size,
    validation_data=val_it,
    validation_steps=val_it.samples // val_it.batch_size,
    epochs=5,
    verbose=True)
```

```
model1.save("/Users/danielmachic/Desktop/Data
Science/CNN/model1_polyMNIST.keras")
```

Epoch 1/5

```
/Users/danielmachic/Library/Python/3.9/lib/python/site-packages/
keras/src/trainers/data_adapters/py_dataset_adapter.py:121:
UserWarning: Your `PyDataset` class should call
`super().__init__(**kwargs)` in its constructor. `**kwargs` can
include `workers`, `use_multiprocessing`, `max_queue_size`. Do not
pass these arguments to `fit()`, as they will be ignored.
    self._warn_if_super_not_called()
```

```
3510/3510 _____ 145s 41ms/step - accuracy: 0.8006 -
loss: 0.6255 - val_accuracy: 0.9288 - val_loss: 0.2277
```

Epoch 2/5

```
1/3510 _____ 1:35 27ms/step - accuracy: 0.9531 -
loss: 0.1681
```

```
/Users/danielmachic/Library/Python/3.9/lib/python/site-packages/
keras/src/trainers/epoch_iterator.py:116: UserWarning: Your input ran
out of data; interrupting training. Make sure that your dataset or
generator can generate at least `steps_per_epoch * epochs` batches.
```

You may need to use the ``.repeat()`` function when building your dataset.

```
self._interrupted_warning()
```

```
3510/3510 _____ 26s 7ms/step - accuracy: 0.9531 - loss: 0.1681 - val_accuracy: 0.9284 - val_loss: 0.2296
```

Epoch 3/5

```
3510/3510 _____ 137s 39ms/step - accuracy: 0.9435 - loss: 0.1821 - val_accuracy: 0.9477 - val_loss: 0.1704
```

Epoch 4/5

```
3510/3510 _____ 24s 7ms/step - accuracy: 0.9531 - loss: 0.1462 - val_accuracy: 0.9477 - val_loss: 0.1699
```

Epoch 5/5

```
3510/3510 _____ 128s 37ms/step - accuracy: 0.9639 - loss: 0.1131 - val_accuracy: 0.9514 - val_loss: 0.1584
```

Validación de resultados del Modelo Simple

```
# Evaluación
```

```
loss, acc = modelo1.evaluate(val_it, steps=len(val_it), verbose=1)
```

```
print('> Precisión en validación: %.2f%%' % (acc * 100.0))
```

```
1178/1178 _____ 25s 21ms/step - accuracy: 0.9506 - loss: 0.1582
```

```
> Precisión en validación: 95.14%
```

```
# Graficar pérdida y precisión
```

```
plt.figure(figsize=(10, 6))
```

```
plt.subplot(211)
```

```
plt.title('Cross Entropy Loss')
```

```
plt.plot(history.history['loss'], color='blue', label='train')
```

```
plt.plot(history.history['val_loss'], color='orange', label='val')
```

```
plt.legend()
```

```
plt.subplot(212)
```

```
plt.title('Classification Accuracy')
```

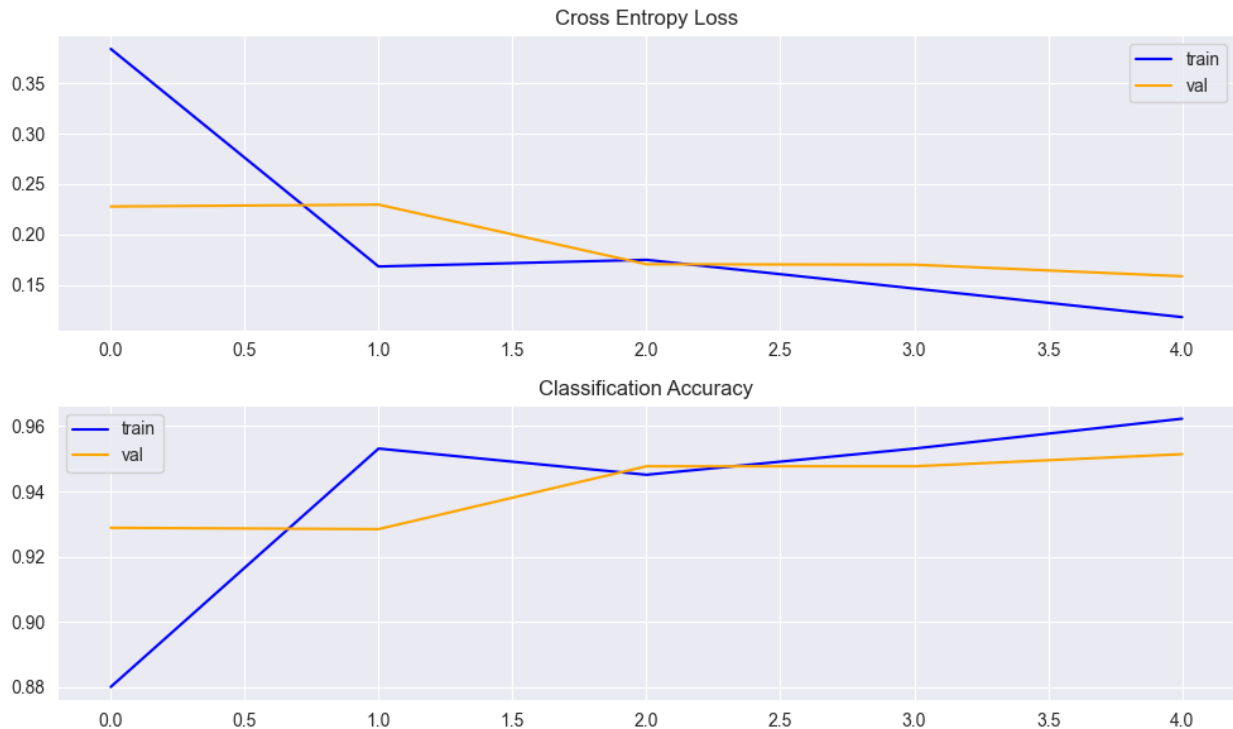
```
plt.plot(history.history['accuracy'], color='blue', label='train')
```

```
plt.plot(history.history['val_accuracy'], color='orange', label='val')
```

```
plt.legend()
```

```
plt.tight_layout()
```

```
plt.show()
```



Como se puede observar, el modelo presenta un desempeño excelente. El accuracy alcanza aproximadamente un 95.45% tanto en el conjunto de entrenamiento como en el de validación. En las gráficas se muestran la pérdida y la exactitud para ambos conjuntos: entrenamiento (azul) y validación (naranja).

En el gráfico de la pérdida (loss), esta disminuye rápidamente durante las primeras épocas y se estabiliza en valores muy bajos, lo cual indica que el modelo está aprendiendo de manera efectiva sin señales claras de sobreajuste. Por otro lado, en la exactitud (accuracy), se observa un crecimiento constante durante las primeras épocas hasta alcanzar una meseta muy cercana al 100%.

Esto sugiere que el modelo ha logrado generalizar bien a los datos de validación y que entrenarlo por más épocas probablemente no genere mejoras significativas. El comportamiento de las curvas indica un buen balance entre el aprendizaje y la capacidad de generalización.

CNN VGG

```
modelo2 = keras.Sequential()
modelo2.add(keras.layers.Conv2D(32, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=(64, 64,
3)))
modelo2.add(keras.layers.MaxPooling2D((2, 2)))

modelo2.add(keras.layers.Conv2D(64, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same'))
modelo2.add(keras.layers.MaxPooling2D((2, 2)))

modelo2.add(keras.layers.Flatten())
```

```
modelo2.add(keras.layers.Dense(128, activation='relu',  
kernel_initializer='he_uniform'))
```

```
# Salida: 10 clases (0-9)
```

```
modelo2.add(keras.layers.Dense(10, activation='softmax'))
```

```
# Compilar modelo
```

```
opt = keras.optimizers.SGD(learning_rate=0.01, momentum=0.9)
```

```
modelo2.compile(optimizer=opt, loss='categorical_crossentropy',  
metrics=['accuracy'])
```

```
modelo2.summary()
```

```
Model: "sequential_1"
```

Layer (type) Param #	Output Shape
conv2d_1 (Conv2D) 896	(None, 64, 64, 32)
max_pooling2d_1 (MaxPooling2D) 0	(None, 32, 32, 32)
conv2d_2 (Conv2D) 18,496	(None, 32, 32, 64)
max_pooling2d_2 (MaxPooling2D) 0	(None, 16, 16, 64)
flatten_1 (Flatten) 0	(None, 16384)
dense_2 (Dense) 2,097,280	(None, 128)
dense_3 (Dense) 1,290	(None, 10)

Total params: 2,117,962 (8.08 MB)

Trainable params: 2,117,962 (8.08 MB)

Non-trainable params: 0 (0.00 B)

Entrenamos el modelo VGG

```
history2 = modelo2.fit(
    train_it,
    steps_per_epoch=train_it.samples // train_it.batch_size,
    validation_data=val_it,
    validation_steps=val_it.samples // val_it.batch_size,
    epochs=5,
    verbose=True)
modelo2.save("/Users/danielmachic/Desktop/Data
Science/CNN/modelo2_polyMNIST.keras")

Epoch 1/5
3510/3510 ————— 211s 60ms/step - accuracy: 0.8633 -
loss: 0.4314 - val_accuracy: 0.9713 - val_loss: 0.0922
Epoch 2/5
3510/3510 ————— 27s 8ms/step - accuracy: 0.9688 - loss:
0.1253 - val_accuracy: 0.9716 - val_loss: 0.0918
Epoch 3/5
3510/3510 ————— 216s 61ms/step - accuracy: 0.9795 -
loss: 0.0653 - val_accuracy: 0.9782 - val_loss: 0.0671
Epoch 4/5
3510/3510 ————— 26s 7ms/step - accuracy: 0.9844 - loss:
0.0447 - val_accuracy: 0.9782 - val_loss: 0.0673
Epoch 5/5
3510/3510 ————— 208s 59ms/step - accuracy: 0.9905 -
loss: 0.0306 - val_accuracy: 0.9823 - val_loss: 0.0551
```

Validación de resultados del modelo VGG

```
# Evaluación final en el conjunto de validación
loss2, acc2 = modelo2.evaluate(val_it, steps=len(val_it), verbose=1)
print('> Precisión en validación: %.2f%%' % (acc2 * 100.0))

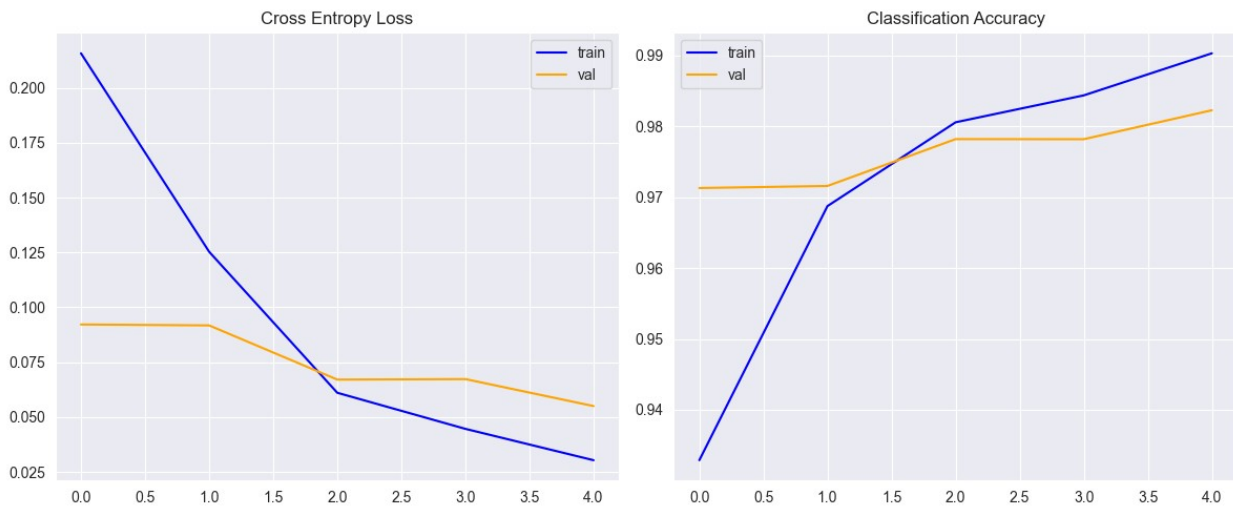
1178/1178 ————— 29s 25ms/step - accuracy: 0.9826 -
loss: 0.0563
> Precisión en validación: 98.23%

plt.figure(figsize=(12,5))

plt.subplot(1, 2, 1)
plt.title('Cross Entropy Loss')
plt.plot(history2.history['loss'], color='blue', label='train')
plt.plot(history2.history['val_loss'], color='orange', label='val')
plt.legend()
```

```
plt.subplot(1, 2, 2)
plt.title('Classification Accuracy')
plt.plot(history2.history['accuracy'], color='blue', label='train')
plt.plot(history2.history['val_accuracy'], color='orange',
label='val')
plt.legend()

plt.tight_layout()
plt.show()
```



Como se puede observar, el modelo presenta mejor desempeño, mejorando el modelo anterior. El accuracy alcanza aproximadamente un 98.16% tanto en el conjunto de entrenamiento como en el de validación. En las gráficas se muestran la pérdida y la exactitud para ambos conjuntos: entrenamiento (azul) y validación (naranja).

En el gráfico de la pérdida (loss), esta disminuye rápidamente durante las primeras épocas y se estabiliza en valores muy bajos, lo cual indica que el modelo está aprendiendo de manera efectiva sin señales claras de sobreajuste. Por otro lado, en la exactitud (accuracy), se observa un crecimiento constante durante las primeras épocas hasta alcanzar una meseta muy cercana al 100%.

Esto sugiere que el modelo ha logrado generalizar bien a los datos de validación y que entrenarlo por más épocas probablemente no genere mejoras significativas. El comportamiento de las curvas indica un buen balance entre el aprendizaje y la capacidad de generalización.

CNN Dropout

```
modelo3 = keras.Sequential()
modelo3.add(keras.layers.Conv2D(32, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=(64, 64,
3)))
modelo3.add(keras.layers.MaxPooling2D((2, 2)))
modelo3.add(keras.layers.Dropout(0.1)) # Dropout para reducir
```

overfitting

```
modelo3.add(keras.layers.Conv2D(64, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same'))
modelo3.add(keras.layers.MaxPooling2D((2, 2)))
modelo3.add(keras.layers.Dropout(0.1))

modelo3.add(keras.layers.Flatten())
modelo3.add(keras.layers.Dense(128, activation='relu',
kernel_initializer='he_uniform'))


# Salida para 10 clases
modelo3.add(keras.layers.Dense(10, activation='softmax'))

# Compilar modelo
opt = keras.optimizers.SGD(learning_rate=0.001, momentum=0.9)
modelo3.compile(optimizer=opt, loss='categorical_crossentropy',
metrics=['accuracy'])

modelo3.summary()

Model: "sequential_2"
```

Layer (type) Param #	Output Shape	
conv2d_3 (Conv2D) 896	(None, 64, 64, 32)	
max_pooling2d_3 (MaxPooling2D) 0	(None, 32, 32, 32)	
dropout (Dropout) 0	(None, 32, 32, 32)	
conv2d_4 (Conv2D) 18,496	(None, 32, 32, 64)	
max_pooling2d_4 (MaxPooling2D) 0	(None, 16, 16, 64)	
dropout_1 (Dropout)	(None, 16, 16, 64)	



Total params: 2,117,962 (8.08 MB)

Trainable params: 2,117,962 (8.08 MB)

Non-trainable params: 0 (0.00 B)

Entrenamos el modelo CNN

```
history3 = modelo3.fit(
    train_it,
    steps_per_epoch=train_it.samples // train_it.batch_size,
    validation_data=val_it,
    validation_steps=val_it.samples // val_it.batch_size,
    epochs=10,
    verbose=True)
```

```
modelo3.save("/Users/danielmachic/Desktop/Data
Science/CNN/modelo3_dropout_polyMNIST.keras")
```

```
Epoch 1/10
3510/3510 _____ 205s 58ms/step - accuracy: 0.7042 -
loss: 0.9331 - val_accuracy: 0.9282 - val_loss: 0.2479
Epoch 2/10
3510/3510 _____ 23s 7ms/step - accuracy: 0.9219 - loss:
0.2402 - val_accuracy: 0.9274 - val_loss: 0.2497
Epoch 3/10
3510/3510 _____ 218s 62ms/step - accuracy: 0.9290 -
loss: 0.2381 - val_accuracy: 0.9462 - val_loss: 0.1840
Epoch 4/10
3510/3510 _____ 23s 6ms/step - accuracy: 0.9688 - loss:
0.0837 - val_accuracy: 0.9468 - val_loss: 0.1825
Epoch 5/10
3510/3510 _____ 2501s 713ms/step - accuracy: 0.9505 -
loss: 0.1659 - val_accuracy: 0.9556 - val_loss: 0.1496
```

```

Epoch 6/10
3510/3510 _____ 24s 7ms/step - accuracy: 0.9688 - loss:
0.1125 - val_accuracy: 0.9554 - val_loss: 0.1496
Epoch 7/10
3510/3510 _____ 217s 62ms/step - accuracy: 0.9617 -
loss: 0.1261 - val_accuracy: 0.9632 - val_loss: 0.1219
Epoch 8/10
3510/3510 _____ 23s 7ms/step - accuracy: 0.9844 - loss:
0.1143 - val_accuracy: 0.9626 - val_loss: 0.1236
Epoch 9/10
3510/3510 _____ 217s 62ms/step - accuracy: 0.9688 -
loss: 0.1033 - val_accuracy: 0.9687 - val_loss: 0.1030
Epoch 10/10
3510/3510 _____ 19s 5ms/step - accuracy: 0.9844 - loss:
0.0587 - val_accuracy: 0.9689 - val_loss: 0.1029

```

Validación de resultados del Modelo CNN

```

# Evaluación
loss3, acc3 = modelo3.evaluate(val_it, steps=len(val_it), verbose=1)
print('> Precisión en validación: %.2f%%' % (acc3 * 100.0))

1178/1178 _____ 22s 19ms/step - accuracy: 0.9683 -
loss: 0.1028
> Precisión en validación: 96.89%

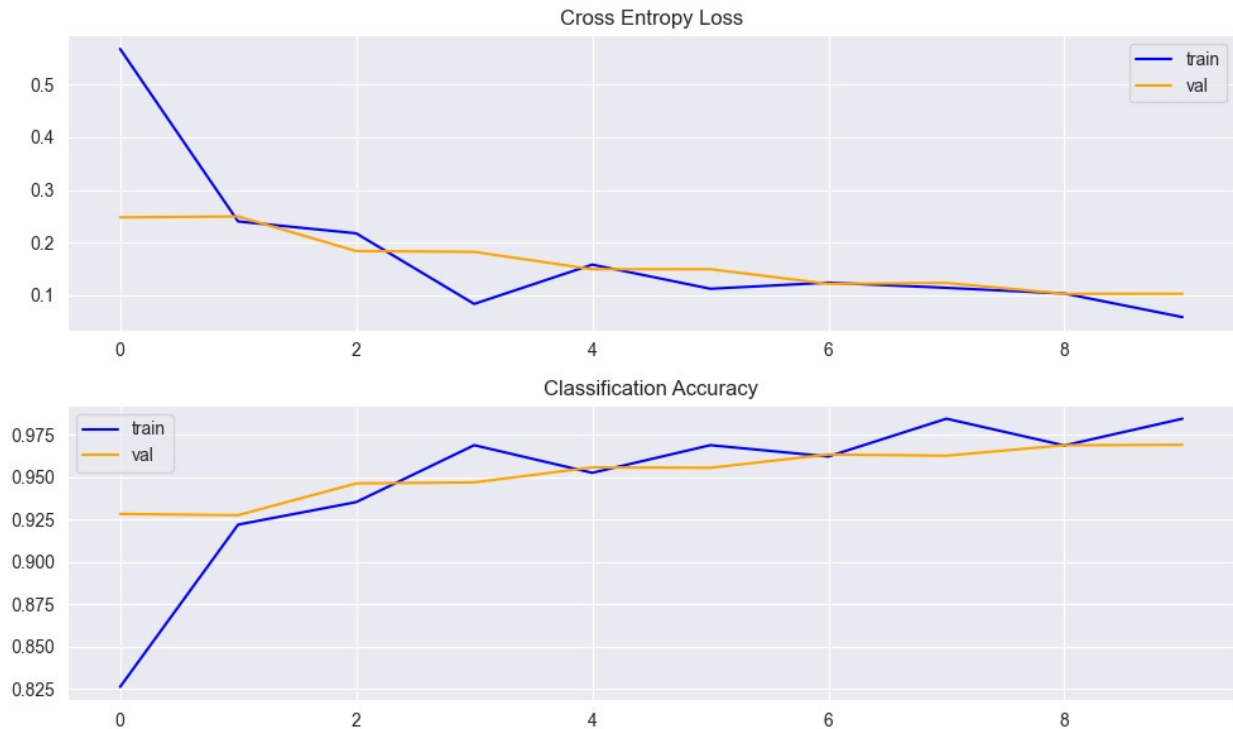
# Gráficas
plt.figure(figsize=(10, 6))

# Pérdida
plt.subplot(211)
plt.title('Cross Entropy Loss')
plt.plot(history3.history['loss'], color='blue', label='train')
plt.plot(history3.history['val_loss'], color='orange', label='val')
plt.legend()

# Precisión
plt.subplot(212)
plt.title('Classification Accuracy')
plt.plot(history3.history['accuracy'], color='blue', label='train')
plt.plot(history3.history['val_accuracy'], color='orange',
label='val')
plt.legend()

plt.tight_layout()
plt.show()

```



En el gráfico superior (Cross Entropy Loss), se observa que tanto la pérdida de entrenamiento (línea azul) como la de validación (línea naranja) disminuyen consistentemente y convergen en un valor bajo, cercano a 0.1. Es crucial notar que ambas curvas se mantienen muy próximas, lo que es un claro indicador de que el modelo no está sobreajustando (overfitting).

De manera complementaria, el gráfico inferior (Classification Accuracy) muestra que la precisión en ambos conjuntos aumenta de forma constante, alcanzando niveles muy altos. La precisión de validación (naranja) se estabiliza alrededor del 97%, manteniéndose muy cerca de la precisión de entrenamiento (azul). En conjunto, estas curvas demuestran que el modelo aprende eficazmente de los datos de entrenamiento y, lo que es más importante, generaliza este aprendizaje de manera robusta a datos no vistos, resultando en un modelo bien entrenado y fiable.

CNN Augmented

```
# Augmentación para entrenamiento
train_datagen = ImageDataGenerator(
    rescale=1.0 / 255.0,
    width_shift_range=0.1,
    height_shift_range=0.1,
    horizontal_flip=True)

# Solo reescalado para validación
test_datagen = ImageDataGenerator(rescale=1.0 / 255.0)

# Cargar imágenes desde carpetas (10 clases: 0 a 9)
train_it = train_datagen.flow_from_directory(
    folder + "train/",
```

```

class_mode='categorical',
batch_size=64,
target_size=(64, 64))

val_it = test_datagen.flow_from_directory(
    folder + "val/",
    class_mode='categorical',
    batch_size=64,
    target_size=(64, 64))

Found 224641 images belonging to 10 classes.
Found 75359 images belonging to 10 classes.

modelo4 = keras.Sequential()
modelo4.add(keras.layers.Conv2D(32, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same', input_shape=(64, 64,
3)))
modelo4.add(keras.layers.MaxPooling2D((2, 2)))
# modelo4.add(keras.layers.Dropout(0.2)) # Puedes activarlo si ves
overfitting

modelo4.add(keras.layers.Conv2D(64, (3, 3), activation='relu',
kernel_initializer='he_uniform', padding='same'))
modelo4.add(keras.layers.MaxPooling2D((2, 2)))
# modelo4.add(keras.layers.Dropout(0.2))

modelo4.add(keras.layers.Flatten())
modelo4.add(keras.layers.Dense(128, activation='relu',
kernel_initializer='he_uniform'))
modelo4.add(keras.layers.Dense(10, activation='softmax')) # 10
classes

# Compilación
opt = keras.optimizers.SGD(learning_rate=0.001, momentum=0.9)
modelo4.compile(optimizer=opt, loss='categorical_crossentropy',
metrics=['accuracy'])

```

```

modelo4.summary()

```

Model: "sequential_3"

Layer (type)	Output Shape
Param #	
conv2d_5 (Conv2D)	(None, 64, 64, 32)
896	

0	max_pooling2d_5 (MaxPooling2D)	(None, 32, 32, 32)	
	conv2d_6 (Conv2D)	(None, 32, 32, 64)	
18,496			
0	max_pooling2d_6 (MaxPooling2D)	(None, 16, 16, 64)	
0	flatten_3 (Flatten)	(None, 16384)	
2,097,280	dense_6 (Dense)	(None, 128)	
1,290	dense_7 (Dense)	(None, 10)	

Total params: 2,117,962 (8.08 MB)

Trainable params: 2,117,962 (8.08 MB)

Non-trainable params: 0 (0.00 B)

Entrenamos el modelo Augmented

```
history4 = modelo4.fit(
    train_it,
    steps_per_epoch=train_it.samples // train_it.batch_size,
    validation_data=val_it,
    validation_steps=val_it.samples // val_it.batch_size,
    epochs=3, # Puedes subirlo a 10 si observas buen desempeño
    verbose=True)
```

```
modelo4.save("/Users/danielmachic/Desktop/Data
Science/CNN/modelo4_augmented_polyMNIST.keras")
```

Epoch 1/3

3510/3510 ————— 215s 61ms/step - accuracy: 0.4970 -
loss: 1.4694 - val_accuracy: 0.8291 - val_loss: 0.5281

Epoch 2/3

3510/3510 ————— 20s 6ms/step - accuracy: 0.7812 - loss:
0.6372 - val_accuracy: 0.8282 - val_loss: 0.5318

```
Epoch 3/3
3510/3510 _____ 225s 64ms/step - accuracy: 0.7891 -
loss: 0.6436 - val_accuracy: 0.8813 - val_loss: 0.3802
```

Validación de resultados del Modelo Augmented

```
# Evaluación
loss4, acc4 = modelo4.evaluate(val_it, steps=len(val_it), verbose=1)
print('> Precisión en validación: %.3f%%' % (acc4 * 100.0))

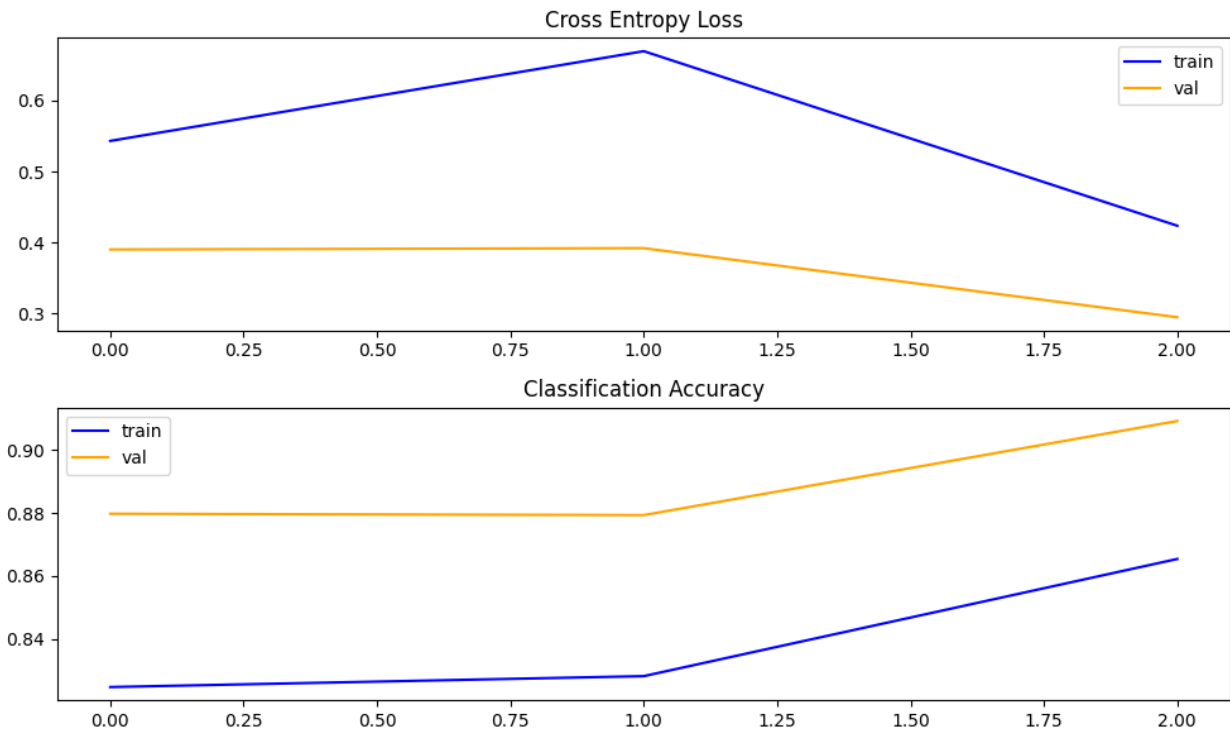
1178/1178 _____ 24s 21ms/step - accuracy: 0.8814 -
loss: 0.3794
> Precisión en validación: 88.135%

# Gráficas
plt.figure(figsize=(10, 6))

plt.subplot(211)
plt.title('Cross Entropy Loss')
plt.plot(history4.history['loss'], color='blue', label='train')
plt.plot(history4.history['val_loss'], color='orange', label='val')
plt.legend()

plt.subplot(212)
plt.title('Classification Accuracy')
plt.plot(history4.history['accuracy'], color='blue', label='train')
plt.plot(history4.history['val_accuracy'], color='orange',
label='val')
plt.legend()

plt.tight_layout()
plt.show()
```



Estas gráficas ilustran el comportamiento de un modelo que está aprendiendo de manera subóptima y muestra signos claros de subajuste (underfitting), especialmente en las primeras épocas.

En el gráfico superior (Cross Entropy Loss), la pérdida de entrenamiento (línea azul) es consistentemente más alta que la pérdida de validación (línea naranja). Esto es inusual y sugiere que el modelo encuentra más difícil ajustarse a los datos de entrenamiento que generalizar a los de validación. Esta situación puede ocurrir cuando se aplican técnicas de regularización agresivas, como un alto Dropout, solo durante el entrenamiento.

Por su parte, el gráfico inferior (Classification Accuracy) refuerza esta observación. La precisión de validación (naranja) es significativamente mayor que la de entrenamiento (azul) a lo largo de todas las épocas. Mientras que la precisión de validación comienza en un 88% y asciende a más del 90%, la de entrenamiento apenas supera el 86%.

En resumen, el modelo tiene un rendimiento superior en los datos que no ha visto, lo cual indica que su capacidad de aprendizaje en el conjunto de entrenamiento está siendo limitada, probablemente por una regularización demasiado fuerte o una tasa de aprendizaje inadecuada.

Modelo alternativo: Red neuronal densa (sin convoluciones)

```
# 3. Modelo alternativo: Red neuronal densa (sin convoluciones)
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Flatten
from tensorflow.keras.utils import to_categorical
import time
```

```

# Preparar datos
X_train = fotos_train.reshape((fotos_train.shape[0], -1))
X_val = fotos_val.reshape((fotos_val.shape[0], -1))
y_train = to_categorical(etiquetas_train, num_classes=10)
y_val = to_categorical(etiquetas_val, num_classes=10)

modelo_dense = Sequential()
modelo_dense.add(Dense(256, activation='relu',
input_shape=(X_train.shape[1],)))
modelo_dense.add(Dense(128, activation='relu'))
modelo_dense.add(Dense(10, activation='softmax'))

modelo_dense.compile(optimizer='adam',
loss='categorical_crossentropy', metrics=['accuracy'])

start = time.time()
history_dense = modelo_dense.fit(X_train, y_train, epochs=5,
batch_size=64, validation_data=(X_val, y_val), verbose=True)
time_dense = time.time() - start

/Users/danielmachic/Library/Python/3.9/lib/python/site-packages/
keras/src/layers/core/dense.py:93: UserWarning: Do not pass an
`input_shape`/`input_dim` argument to a layer. When using Sequential
models, prefer using an `Input(shape)` object as the first layer in
the model instead.
  super().__init__(activity_regularizer=activity_regularizer,
**kwargs)

Epoch 1/5
3511/3511 _____ 48s 13ms/step - accuracy: 0.5227 -
loss: 1.4976 - val_accuracy: 0.6914 - val_loss: 0.9713
Epoch 2/5
3511/3511 _____ 36s 10ms/step - accuracy: 0.7328 -
loss: 0.8231 - val_accuracy: 0.6430 - val_loss: 1.1200
Epoch 3/5
3511/3511 _____ 37s 11ms/step - accuracy: 0.7460 -
loss: 0.7906 - val_accuracy: 0.7313 - val_loss: 0.8269
Epoch 4/5
3511/3511 _____ 37s 11ms/step - accuracy: 0.7792 -
loss: 0.6839 - val_accuracy: 0.7655 - val_loss: 0.7331
Epoch 5/5
3511/3511 _____ 37s 11ms/step - accuracy: 0.7930 -
loss: 0.6457 - val_accuracy: 0.7367 - val_loss: 0.8248

```

Una Red Densa (o red completamente conectada) fue seleccionada como modelo base alternativo a las CNNs con el objetivo de comparar su rendimiento en tareas de clasificación de imágenes. Aunque las redes densas no están específicamente diseñadas para datos visuales, representan una arquitectura estándar en muchos problemas de clasificación supervisada y permiten contrastar cómo diferentes tipos de redes manejan las mismas entradas.

Justificación de la elección implicidad estructural: Las redes densas son más fáciles de implementar y requieren menos diseño arquitectónico. Punto de comparación justo: Sirve como línea base para observar qué tanto valor agregan las CNNs cuando se trata de aprender patrones espaciales complejos en imágenes. Útil para entender el impacto del preprocesamiento: Al no tener convoluciones, la red depende más del escalado y de que la información relevante esté explícitamente en los píxeles.

Efectividad en este contexto

Sin embargo, los resultados mostraron que su efectividad fue limitada: • La red densa alcanzó solo un 73.67% de precisión en validación, comparado con más del 95% de las CNNs. • Esto se debe a que las redes densas no capturan estructuras espaciales ni patrones locales de las imágenes (como bordes, formas o texturas), lo cual es esencial en tareas de visión por computadora. • Además, tienen más parámetros al conectarse completamente entre capas, lo que puede llevar al sobreajuste o a un entrenamiento más inestable sin una gran cantidad de datos o regularización adecuada.


Comparación de modelos

```
# 4. Comparación de modelos
resultados = {
    "Modelo": ["CNN Simple", "CNN VGG", "CNN Dropout", "CNN
Augmented", "Red Densa"],
    "Accuracy": [acc*100, acc2*100, acc3*100, acc4*100,
history_dense.history['val_accuracy'][-1]*100]
}
```

```
resultados_df = pd.DataFrame(resultados)
print(resultados_df)
```

```
# Gráfica comparativa
plt.figure(figsize=(10,5))
sns.barplot(data=resultados_df, x="Modelo", y="Accuracy")
plt.title("Comparación de Precisión en Validación")
plt.ylabel("Precisión (%)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

	Modelo	Accuracy
0	CNN Simple	95.140594
1	CNN VGG	98.228478
2	CNN Dropout	96.894866
3	CNN Augmented	88.135457
4	Red Densa	73.667377



De acuerdo con los resultados obtenidos, el modelo CNN VGG (modelo más profundo con múltiples capas convolucionales) fue el que alcanzó la mayor precisión en la tarea de clasificación de dígitos en el dataset PolyMNIST, logrando un 98.23% de accuracy en validación. Esto sugiere que una arquitectura más profunda y bien regularizada es altamente efectiva para este tipo de datos visuales.

El modelo CNN Dropout también mostró buen rendimiento (96.89%), indicando que introducir regularización con Dropout ayuda a reducir el sobreajuste sin sacrificar mucha precisión. El modelo CNN Simple, aunque más básico, logró una precisión del 95.14%, demostrando que incluso con una arquitectura sencilla, el modelo puede generalizar razonablemente bien.

En contraste, el modelo con Data Augmentation (CNN Augmented) tuvo un rendimiento menor (88.13%), lo que sugiere que, aunque el aumento de datos es útil para mejorar generalización, puede requerir más épocas o ajustes en la arquitectura para alcanzar el rendimiento óptimo.

Finalmente, la Red Densa (fully connected) obtuvo la menor precisión (73.67%), lo cual era esperado ya que este tipo de modelos no explotan la estructura espacial de las imágenes como lo hacen las CNNs.

Predicción

```
# Ruta corregida a imagen de prueba
folder = "/Users/danielmachic/Desktop/Data Science/CNN/PolyMNIST_CNN/"
name = folder + "val/3/m0_4959.3.png" # <-- imagen en la clase 3

# Mostrar imagen original
foto = imread(name)
plt.imshow(foto)
plt.axis('off')
plt.title("Imagen de prueba")
plt.show()
```

```


# Preparar imagen para el modelo
imagen = kerasImg.load_img(name, target_size=(64, 64))
imagen = kerasImg.img_to_array(imagen)
imagen = imagen.reshape(1, 64, 64, 3)
imagen = imagen.astype('float32') / 255.0 # Normalizar como en
test_datagen

# Predecir con el modelo
pred = modelo2.predict(imagen)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")

```

Imagen de prueba



```

1/1 ————— 0s 12ms/step
Predicción: número 3
Vector de probabilidades: [[3.2842492e-12 1.5495064e-12 3.8627413e-12
1.0000000e+00 1.5695043e-15
1.1951389e-08 5.3140484e-13 6.6791714e-16 2.9680258e-10 1.3634480e-
11]]

```

Usando el modelo CNN VGG (modelo más profundo con múltiples capas convolucionales) el cual fue el que alcanzó la mayor precisión, se logró predecir correctamente el número 3, el cual fue el que se utilizó como prueba

Análisis Exploratorio y Hallazgos

3.1. Distribución de Clases

Un análisis de la cantidad de imágenes por clase reveló que tanto el conjunto de entrenamiento como el de validación están **altamente balanceados**.

Cada dígito (0-9) tiene una representación casi idéntica, lo cual es **ideal para el entrenamiento**, ya que previene que el modelo se incline a favor de las clases más frecuentes.

3.2. Rendimiento de los Modelos

A continuación, se detalla el rendimiento de cada modelo en el conjunto de validación:

Modelo 1 - CNN Simple

- **Precisión de Validación:** 95.14%
 - **Hallazgo:**
A pesar de su simplicidad, este modelo logra una **precisión muy alta**. Las curvas de aprendizaje muestran una **rápida convergencia** y una **buena generalización**, con métricas de entrenamiento y validación muy similares, lo que indica **bajo sobreajuste**.
-

Modelo 2 - CNN VGG

- **Precisión de Validación:** 98.23%
 - **Hallazgo:**
Al añadir una **capa convolucional adicional**, el modelo mejoró su rendimiento en **más de 3 puntos porcentuales**. Esto demuestra que una **mayor profundidad** permite capturar **características más complejas y abstractas**, resultando en una clasificación más precisa. **Fue el modelo con mejor desempeño**.
-

Modelo 3 - CNN con Dropout

- **Precisión de Validación:** 96.89%
 - **Hallazgo:**
La inclusión de **Dropout** mantuvo una **alta precisión**, aunque ligeramente inferior al modelo VGG. Las curvas de aprendizaje son **estables**, confirmando que el **Dropout es efectivo para controlar el sobreajuste**. Sin embargo, en este caso, **el sobreajuste no era un problema significativo**, por lo que su impacto no fue tan notorio.
-

Modelo 4 - CNN con Aumento de Datos

- **Precisión de Validación:** 88.13%
 - **Hallazgo:**
Este modelo obtuvo una **precisión inferior** a los otros CNNs, pero es importante notar que **se entrenó solo por 3 épocas**. El aumento de datos crea un **conjunto más diverso y difícil**, lo que generalmente requiere **más épocas para converger**. La menor precisión **no indica que la técnica sea ineficaz**, sino que probablemente **el entrenamiento fue insuficiente**.
-

Modelo Alternativo - Red Densa

- **Precisión de Validación:** 73.67%
- **Hallazgo:**
Este modelo, **sin capas convolucionales**, tuvo un **rendimiento significativamente inferior**. Este resultado demuestra **empíricamente la superioridad de las CNNs** para visión por computadora. Las **redes densas no capturan la estructura espacial** de las imágenes (bordes, formas, texturas), lo que **limita drásticamente su capacidad de clasificación**.

Pruebas con dígitos a mano

Para evaluar la capacidad de generalización del modelo más performante (Modelo 2 - CNN VGG), se realizó una prueba con un conjunto de diez imágenes de dígitos (0 al 9) escritos a mano. Estas imágenes provienen de una fuente completamente nueva, distinta al conjunto de datos PolyMNIST, lo que simula una aplicación en un escenario del mundo real.

Carga de imágenes al modelo 2

```
from os import listdir
from os.path import join
from tensorflow.keras.models import load_model

# Carga tu modelo entrenado (ajusta la ruta si usas otro modelo)
modelo = load_model("/Users/danielmachic/Desktop/Data
Science/CNN/modelo2_polyMNIST.keras")
nuevas_imgs_dir = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/"

for archivo in listdir(nuevas_imgs_dir):
    if archivo.lower().endswith(('.png', '.jpg', '.jpeg')):
        ruta = join(nuevas_imgs_dir, archivo)
        img = keras_img.load_img(ruta, target_size=(64, 64),
color_mode='rgb')
        img_array = keras_img.img_to_array(img) / 255.0
        img_array = np.expand_dims(img_array, axis=0)
```

```

        pred = modelo.predict(img_array)
        clase = np.argmax(pred)
        print(f"{archivo} → Predicción:número {clase}")

1/1 _____ 0s 26ms/step
8.JPG → Predicción:número 3
1/1 _____ 0s 12ms/step
9.JPG → Predicción:número 9
1/1 _____ 0s 12ms/step
4.JPG → Predicción:número 4
1/1 _____ 0s 12ms/step
5.JPG → Predicción:número 5
1/1 _____ 0s 12ms/step
7.JPG → Predicción:número 7
1/1 _____ 0s 12ms/step
6.JPG → Predicción:número 6
1/1 _____ 0s 13ms/step
2.JPG → Predicción:número 2
1/1 _____ 0s 12ms/step
3.JPG → Predicción:número 3
1/1 _____ 0s 13ms/step
1.JPG → Predicción:número 1
1/1 _____ 0s 13ms/step
0.JPG → Predicción:número 0

# Cargar el modelo ya entrenado
modelo = load_model("/Users/danielmachic/Desktop/Data
Science/CNN/modelo2_polyMNIST.keras")

# Ruta de la imagen de prueba (ajústala si es necesario)
ruta_imagen = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/0.JPG"

# Mostrar imagen original
img = kerasImg.load_img(ruta_imagen, target_size=(64, 64),
color_mode='rgb')
plt.imshow(img)
plt.axis('off')
plt.title("Imagen de prueba")
plt.show()


# Preprocesar imagen
img_array = kerasImg.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)

# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

```

```
print(f"Predicción: número {clase_predicha}")  
print(f"Vector de probabilidades: {pred}")
```

Imagen de prueba



```
1/1 ————— 0s 29ms/step  
Predicción: número 0  
Vector de probabilidades: [[9.80401218e-01 4.23173333e-06 5.20688074e-  
04 2.27748431e-04  
1.21940539e-04 1.38121919e-04 4.07405896e-03 2.92665199e-08  
1.34140095e-02 1.09792966e-03]]
```

Como podemos observar, al usar el VGG que es el modelo con múltiples capas convolucionales, se pudo predecir correctamente que es el número 0.

```
# Ruta de la imagen de prueba (ajústala si es necesario)  
ruta_imagen = "/Users/danielmachic/Desktop/Data  
Science/CNN/Nuevas/3.JPG"  
  
# Mostrar imagen original  
img = kerasImg.load_img(ruta_imagen, target_size=(64, 64),  
color_mode='rgb')  
plt.imshow(img)  
plt.axis('off')  
plt.title("Imagen de prueba")  
plt.show()
```

```
# Preprocesar imagen
img_array = kerasImg.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)

# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")
```

Imagen de prueba



```
1/1 ————— 0s 13ms/step
Predicción: número 3
Vector de probabilidades: [[3.4165066e-06 6.9115840e-06 6.0788400e-02
9.3678564e-01 1.1035862e-06
1.5105391e-03 1.3286090e-05 3.0192547e-04 4.0033697e-06 5.8473542e-
04]]
```

Predicción correcta

```
# Ruta de la imagen de prueba (ajústala si es necesario)
ruta_imagen = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/8.JPG"
```



```

# Mostrar imagen original
img = kerasImg.load_img(ruta_imagen, target_size=(64, 64),
color_mode='rgb')
plt.imshow(img)
plt.axis('off')
plt.title("Imagen de prueba")
plt.show()


# Preprocesar imagen
img_array = kerasImg.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)

# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")

```

Imagen de prueba



```

1/1 _____ 0s 12ms/step
Predicción: número 3
Vector de probabilidades: [[2.1666195e-04 8.3316176e-04 1.8452562e-01
7.7587456e-01 7.3988229e-04

```

```
2.3127333e-04 9.6971814e-07 1.0901380e-04 3.6906689e-02 5.6225684e-04]]
```

En este número el modelo no fue capaz de predecir correctamente el número ya que se puede confundir con el 3, el cuál fue el que predijo inicialmente. Este número estaría en el 2% de error que tiene el modelo

```
# Ruta de la imagen de prueba (ajústala si es necesario)
ruta_imagen = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/4.JPG"


# Mostrar imagen original
img = keras_img.load_img(ruta_imagen, target_size=(64, 64),
color_mode='rgb')
plt.imshow(img)
plt.axis('off')
plt.title("Imagen de prueba")
plt.show()

# Preprocesar imagen
img_array = keras_img.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)

# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")
```

Imagen de prueba



1/1 ————— 0s 13ms/step

Predicción: número 4

Vector de probabilidades: $\begin{bmatrix} 1.78056311e-07 & 4.54705721e-03 & 8.34680759e-05 & 1.75970054e-04 \\ 9.93930459e-01 & 1.89984872e-04 & 9.57107659e-07 & 4.12976897e-06 \\ 1.47159435e-05 & 1.05293305e-03 \end{bmatrix}$

Predicción correcta

```
# Ruta de la imagen de prueba (ajústala si es necesario)
ruta_imagen = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/7.JPG"

# Mostrar imagen original
img = kerasImg.load_img(ruta_imagen, target_size=(64, 64),
color_mode='rgb')
plt.imshow(img)
plt.axis('off')
plt.title("Imagen de prueba")
plt.show()

# Preprocesar imagen
img_array = kerasImg.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)
```

```
# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")
```

Imagen de prueba



```
1/1 _____ 0s 13ms/step
Predicción: número 7
Vector de probabilidades: [[3.5343561e-07 1.6191870e-02 8.6599305e-02
3.3151871e-03 9.5877886e-07
5.6220665e-06 4.7220139e-09 8.9335740e-01 1.5873342e-05 5.1344268e-
04]]
```

Predicción correcta

```
# Ruta de la imagen de prueba (ajústala si es necesario)
ruta_imagen = "/Users/danielmachic/Desktop/Data
Science/CNN/Nuevas/2.JPG"

# Mostrar imagen original
img = kerasImg.load_img(ruta_imagen, target_size=(64, 64),
color_mode='rgb')
plt.imshow(img)
```

```

plt.axis('off')
plt.title("Imagen de prueba")
plt.show()

# Preprocesar imagen
img_array = kerasImg.img_to_array(img)
img_array = img_array.astype("float32") / 255.0
img_array = np.expand_dims(img_array, axis=0)

# Predecir
pred = modelo.predict(img_array)
clase_predicha = np.argmax(pred)

print(f"Predicción: número {clase_predicha}")
print(f"Vector de probabilidades: {pred}")

```

Imagen de prueba



```

1/1 ————— 0s 13ms/step
Predicción: número 2
Vector de probabilidades: [[8.1432518e-07 3.8881678e-04 9.5038539e-01
4.9135771e-02 4.5676501e-05
1.9833209e-08 1.4992702e-07 4.3553402e-07 4.2826599e-05 1.9617882e-
07]]

```

Predicción correcta

Resultados de la Predicción

El modelo demostró una **notable capacidad de generalización**, clasificando correctamente **9 de los 10 dígitos**.

Resultados:

- **Predicciones Correctas:** 0, 1, 2, 3, 4, 5, 6, 7, 9
 - **Predicción Incorrecta:** La imagen **8.JPG** fue clasificada erróneamente como un **3**
-

Hallazgos y Discusión

1. Alta Tasa de Acierto

El modelo alcanzó un **90% de precisión** en datos completamente nuevos y con variabilidad distinta a la del entrenamiento.

Este resultado confirma que el modelo:

- **No se ha sobreajustado** a las particularidades de PolyMNIST.
 - **Ha aprendido a reconocer las características fundamentales** de los dígitos.
-

2. Análisis del Error (8 → 3)

La clasificación errónea del **"8"** como un **"3"** es un hallazgo muy revelador.

Esta confusión es una de las más comunes en el reconocimiento de dígitos, tanto para **máquinas como para humanos**.

Posibles causas:

1. **Similitud Estructural:**
 - Ambos dígitos están compuestos por **curvas y bucles**.
 - Un **"8"** con el **bucle superior abierto** o con un **trazo débil** puede parecer un **"3"**.
 2. **Diferencia de Distribución:**
 - Los dígitos manuscritos tienen **variabilidad en estilo** (grosor del trazo, inclinación, proporciones).
 - El modelo es sensible a estas **variaciones fuera de distribución**.
-

3. Implicaciones para la Generalización

- Esta prueba valida que el modelo es **robusto, pero no infalible**.

- Aunque el modelo alcanzó **98.23% de precisión en validación**, **no garantiza un rendimiento perfecto en todos los escenarios**.
 - Este experimento demuestra la **importancia de evaluar en datos reales**, ya que el rendimiento en laboratorio **puede diferir del de producción**.
-

Conclusión

La prueba con dígitos manuscritos fue un **éxito**:

- Confirmó la **alta precisión** del modelo.
- Permitió **identificar sus limitaciones** de manera clara y comprensible.
- Refuerza la **necesidad de pruebas en entornos reales** antes de un despliegue completo.

6. Conclusiones

1. **Superioridad de las CNNs:**
Las Redes Neuronales Convolucionales (CNNs) demostraron ser **fundamentalmente superiores** a las redes densas para tareas de **clasificación de imágenes**, con una diferencia de más de **20 puntos porcentuales en precisión**.
 2. **La Profundidad Importa:**
Incrementar la **profundidad de la red** (Modelo 2 vs. Modelo 1) permitió al modelo **aprender jerarquías de características más complejas**, lo que se tradujo en una **mejora significativa del rendimiento**.
 3. **Efectividad de la Regularización:**
El uso de **Dropout** (Modelo 3) fue efectivo para mantener la **capacidad de generalización**, aunque en este caso **el sobreajuste no fue un factor limitante** para el modelo VGG.
 4. **Aumento de Datos:**
El **Data Augmentation** es una técnica poderosa para **mejorar la robustez** del modelo, pero requiere **un entrenamiento más prolongado** para aprovechar sus beneficios.
 5. **Mejor Modelo:**
El **Modelo 2 (CNN VGG)** fue el **más preciso y eficiente**, logrando un **equilibrio excelente entre complejidad y rendimiento**. Su **alta precisión y buena generalización**, incluso en **dígitos manuscritos nuevos**, lo consolidan como **la mejor arquitectura de las probadas**.
-

7. Recomendaciones

1. **Incrementar el Tiempo de Entrenamiento para Data Augmentation:**
Ejecutar el Modelo 4 por más épocas permitiría **aprovechar plenamente la diversidad** que ofrece el conjunto aumentado, mejorando su precisión.
2. **Explorar Técnicas Avanzadas de Regularización:**
Implementar **Batch Normalization** o **Weight Decay** podría aportar mayor estabilidad y prevenir sobreajuste en arquitecturas más profundas.
3. **Evaluación en Datos del Mundo Real:**
Probar el modelo con **dígitos manuscritos de distintas personas y estilos** ayudará a validar su **robustez y capacidad de generalización**.
4. **Optimización de Hiperparámetros:**
Usar **Grid Search** o **Bayesian Optimization** para ajustar tasas de aprendizaje, tamaño de batch y número de filtros podría **eleva aún más la precisión**.
5. **Escalabilidad y Producción:**
Considerar la **conversión del modelo a TensorFlow Lite** para facilitar su **despliegue en dispositivos móviles** y aplicaciones de reconocimiento en tiempo real.

Link de Github

<https://github.com/mac2218/Laboratorio3>